CutMix-SupCon: CutMix 증강과 지도 대조 학습을 활용한 멀티모달 기반 감정인식*

김준우○, 김수영, 윤치현, 황지연, 정호영
경북대학교 일반대학원 인공지능학과
{kaen2891, swimai, exo1926, chichi8969, hoyjung}@knu.ac.kr

CutMix-SupCon: Supervised Contrastive Learning with CutMix Augmentation for Multimodal-based Emotion Recognition

June-Woo Kim○, Suyoung Kim, Chihyeon Yoon, Jiyeon Hwang, Ho-Young Jung
Department of Artificial Intelligence, Graduate School, Kyungpook National University

요 약

사람-기계 간의 상호작용이 강조되는 대화형 감정인식 기술은 활발히 연구되는 분야이다. 감정인식을 위한 최첨단 딥러닝 모델이 개발되고 있지만, 정제된 멀티모달 데이터 샘플의 부족으로 인해 실용화로 진행되기에는 여전히 한계점이 존재한다. 이는 학습된 모델의 과적합을 발생시킬 뿐만 아니라 일반화 능력이 감소될 수 있는 치명적인 문제로 초래될 수 있다. 멀티모달 데이터셋의 불충분한 문제를 완화하기 위해 본 연구에서는 잠재 공간에서 혼합된 멀티모달 표현 학습을 위한 CutMix 증강을 이용한 지도 대조 학습 방법인 CutMix-SupCon을 제안한다. 제안된 CutMix-SupCon 방법은 부족한 멀티모달 데이터 문제를 해결함과 동시에 대조 학습 기반의 혼합 대조 손실을 통해 음성-텍스트의 결합된 표현이 원본과 얼마나 유사한지를 학습할 수 있다. 실제로 제안한 방법은 KEMDy19 데이터셋에서 기존 멀티모달 결합 및 Mixup, CutMix 기반 방법 대비 우수한 성능을 입증했다. 본 논문의 코드는 다음 링크로부터 재현이 가능하다: https://github.com/kaen2891/CutMix-SupCon-MultiModal

1. 서 론

딥러닝 기반의 멀티모달 감정인식은 언어 및 비언어적 행동으로부터 사용자의 감정을 분석하는 연구 분야이다. 멀티모달 기반의 감정인식을 위한 최첨단 딥러닝 모델은 여전히 연구되고 있다. [1]에서는 Dual-RNN 모델 기반의 음성 및 텍스트의 특징 표현을 결합하여 감정인식을 진행하였다. 초기의 서로 다른 모달 간의 결합 방법은 융합된 특징의 상관관계를 파악하기에 부족하였으며, 위의 문제를 해결하기 위해 다양한 연구들이 제안되었다. [2]에서는 CNN 기반 어텐션 구조를 사용하여 서로 다른 음성 샘플의 세그먼트와 단어 샘플의 관계를 학습하는 방법을 보였다. [3]에서는 Bi-LSTM으로 추출된 특징에 어텐션을 적용함으로써 기존 모달 간의 특징 결합보다 개선된 성능을 보였다. [4]에서는 Bi-GRU 기반의 융합 매커니즘을 통해 서로 다른 멀티모달 특징을 계층적으로 결합하였다.

한편, 정제된 멀티모달 데이터는 구조적으로 획득하기 어려운 문제가 있으며, 부족한 데이터 샘플의 문제로 인해 학습된 딥러닝 기반 네트워크의 실용화가 진행되기에는 여전히 한계점이 존재한다. 앞서 소개한 선행 연구들은 실제 환경의 부족한 데이터 문제는 고려하지 않고, 멀티모달 결합 관점에 대해서만 집중되는 경향이 존재한다.

제한된 데이터 환경에서 분류 문제를 해결하기 위해 서로 다른 데이터의 샘플을 혼합하는 Mixup [5] 또는 CutMix [6]와 같은 방법은 이미지 분야에서 처음 제안되었지만 도메인에 상관없이 널리 적용되는 증강 기법 중 하나이다. 이와 더불어 데이터의 레이블 정보를 활용한 지도 대조 학습 [7] (SupCon: Supervised Contrastive Learning) 방법은 하나의 positive 샘플이 아닌 같은 클래스에 속하는 샘플들도 positive로 간주함에 따라 기존 자기지도 대조 학습에서 같은 클래스를 negative로 고려하여 동일 클래스에 속하는 다른 샘플들의 거리가 멀어지게 되는 문제를 해결하였다. SupCon 방법은 결과적으로 단순히 정답 확률만을 고려하여 학습되는 Cross-Entropy (CE) 손실 함수에 비해 특징표현을 기반으로 분류 작업을 해결함으로써 기존 Cross-Entropy 손실 함수를 능가하는 모습을 보였다.

이에 영감을 받아 본 연구에서는 멀티모달 데이터셋의 불충분한 문제를 해결하기 위해 CutMix-SupCon 방법을 제안한다. 제안된 CutMix-SupCon 방법은 잠재 공간에서 추출된 음성-텍스트 모달 간의 결합된 특징표현으로부터 혼합된 특징표현을 만들고, 혼합 대조 손실을 통해 음성-텍스트의 결합된 멀티모달 특징표현이 원본과 얼마나 유사한지에 대한 목적 함수를 통해 모델의 학습이 진행된다. 이를 위해 다국어 데이터셋 [8]으로 사전학습 이후 한국어로 미세조정된 wav2vec 2.0 [9] 음성 모델과 한국어 KLUE [10] 데이터셋 기반으로 사전학습된 RoBERTa [11] 텍스트 모델을 음성-텍스트 특징표현 추출 모델로 사용한다.

제안하는 방법의 효과성을 입증하기 위해, ETRI에서 공개한 KEMDy19 [12] 데이터셋을 사용하여 멀티모달 기반 감정인식 성능 평가를 진행한다. 실제로 제안한 CutMix-SupCon 방법은 실험 결과에서 기존 멀티모달 결합 및 Mixup, CutMix 기반 방법 대비 우수한 성능을 입증한다. 본 연구진은 CutMix-SupCon 방법을 통해 감정인식 작업 뿐만 아니라 멀티모달 기반의 다양한 작업에서 부족한 데이터 문제를 해결할 수 있을 것으로 기대한다.

본 연구는 과학기술정보통신부 및 정보통신기획평가원의 대학ICT연구센터지원사업의 연구결과로 수행되었음 (IITP-2023-2020-0-01808*)

2. 방 법

제안하는 멀티모달 CutMix-SupCon 방법은 크게 멀티모달 특징표현 결합, CutMix, 그리고 이를 활용한 SupCon 방법으로 나뉘어지며, 전체 흐름도는 그림 1과 같다.

2.1 멀티모달 특징표현 추출 및 결합

본 연구에서는 멀티모달 특징표현 추출 및 결합을 위해 다국어로 사전학습 [8] 이후 한국어로 미세조정된 wav2vec 2.0 [9] 모델과 한국어 KLUE [10] 기반으로 학습된 RoBERTa [11] 모델을 사용한다. 음성 특징표현은 1024차원으로 추출되어 768

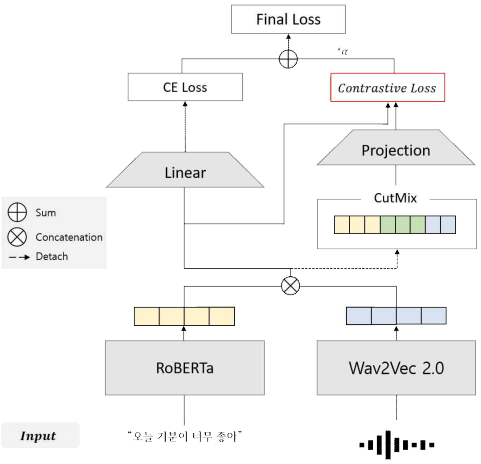

그림 1 CutMix-SupCon 기반 멀티모달 감정인식 아키텍처

차원의 선형 계층을 통과하고, 텍스트 특징표현은 768차원으로 추출된다. 각 모달의 특징표현은 단순 결합 혹은 Mixup 방법 사용시에 AveragePool2D가 바로 적용되어 분류 작업이 이루어지는데, CutMix 및 지도 대조 학습 방법에서는 멀티모달 특징표현의 시간 정보까지 포함하여 증강 및 혼합 작업이 진행된다. 두 방법에 대해서는 최종 분류 예측에서 시간 정보를 삭제하기 위하여 결합된 혼합 특징표현에 대해 AveragePool2D가 사용된다.

2.2 CutMix 기반 멀티모달 혼합 증강

본 연구에서는 데이터셋의 불충분한 문제를 완화하기 위해 증강된 데이터 샘플로 모델을 정규화하기 위한 증강 기법 중 하나인 CutMix 방법을 사용한다. 멀티모달 CutMix 특징표현 혼합 방법은 결합된 멀티모달 특징표현 z와 레이블 y에 대하여 두 개의 샘플 $(z_A, y_A), (z_B, y_B)$로부터 새로운 샘플 $(\tilde{z}, \tilde{y})$를 아래의 식과 같이 만들 수 있다.

$$\tilde{z} = M \odot z_A + (1 - M) \odot z_B$$

$$\tilde{y} = \lambda y_A + (1 - \lambda) y_B$$

여기에서 λ는 두 데이터의 결합 비율로, 0과 1사이에서 정의되는 베타 분포로부터 추출된다. 본 연구에서는 베타 분포를 1.0으로 주어 균등분포로 설정하였다.

2.3 CutMix-SupCon

CutMix 기법으로부터 증강된 멀티모달 특징표현을 위한 적절한 손실 함수를 적용하기 위해, 잠재 공간내에서 혼합된 정보를 구분하여 효과적인 학습을 가능하게 하는 CutMix-SupCon 방법을 제안한다. 이에 대한 혼합 대조 학습의 목적 함수는 다음과 같이 정의된다:

$$L_{CL} = \sum_{i \in I} \frac{1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(z_i \cdot \tilde{z}_p / \tau)}{\sum_{a \in A(i)} \exp(z_i \cdot \tilde{z}_a / \tau)}.$$

z는 결합된 멀티모달 특징표현, $\tilde{z}$는 CutMix로 z가 혼합(증강)된 특징표현이며, 이때 ReLU를 포함한 두 개의 선형 계층으로 이루어진 그림 1의 Projection 계층을 거친다. I는 인덱스 단위, τ는 코사인 유사도를 제어하기 위한 temperature이다. $A(i)$는 모든 positive 및 negative 샘플의 인덱스 집합이고, $P(i) = \{p \in A(i) : \tilde{y}_p = \tilde{y}_i \cup \tilde{y}_p = \tilde{y}_{mix_i}\}$는 배치 내에서 동일한 클래스의 모든 positive 인덱스와 혼합된 클래스 인덱스 집합을 의미한다. 즉, 수식 L_{CL}의 분자에는 positive 쌍이 포함되고, 분모에는 positive와 negative 쌍이 모두 포함되어 있다. 이를 통해 제안하는 CutMix-SupCon 방법의 최종 손실 함수는 다음과 같다:

$$L = L_{CE} + \alpha L_{CL}.$$

L_{CE}는 z와 y를 이용하는 범주형 CE 손실 함수를 나타내며, 혼합 비율 α를 통해 모델은 혼합된 멀티모달 특징표현이 원본 샘플의 고유 정보를 얼마나 포함해야 하는지를 학습한다.

3. 실험 및 결과

3.1 실험 세팅

멀티모달 기반 감정인식을 평가를 위해 본 실험에서는 KEMDy19 [12] 데이터셋을 사용한다. 중복된 파일, 음성의 발화 세그먼트, 20초 이상의 음성 파일 제거 등의 전처리 작업이 진행되었으며, 이를 통해 10,214개의 데이터 샘플을 확보하였다. 학습 및 평가셋은 8:2로 무작위하게 구분하여 진행하였다.

본 연구에서는 텍스트, 음성, 멀티모달 특징표현 기반의 CE 손실 함수, Mixup, CutMix, 그리고 제안하는 CutMix-SupCon 실험에 대해 보고한다. 실험에 사용된 배치 크기는 각 GPU 별로 4이며, 4개의 GPU가 사용되었다. 학습률은 모두 5e-5, 에폭은 10, 옵티마이저는 AdamW가 사용되었으며, 전체 학습 스텝의 30%까지 선형으로 warmup 되었다. Mixup, CutMix, 그리고 CutMix-SupCon에 1.0의 λ값이 사용되었다. τ와 α의 기본값은 각각 0.2, 0.5가 사용되었다.

감정인식 평가를 위해 Macro F1-Score를 기준 척도로 사용한다. 이는 모델이 레이블 불균형을 고려하지 않고 얼마나 정확하게 맞추는지 확인할 수 있다. 또한, 분류 정확도에 대한 결과도 함께 제공한다.

3.2 주요 결과

Input	Method	Acc (%)	F1-score (%)
Text	Cross-Entropy	73.42	69.32
Audio		72.59	67.13
Text+Audio		73.57	69.08
Text	Mixup	71.76	67.37
Audio		71.46	65.89
Text+Audio		72.39	68.94
Text	CutMix	72.93	69.37
Audio		71.76	65.94
Text+Audio		74.74	70.77
Text	CutMix-SupCon (ours)	72.49	**69.72**
Audio		72.54	**68.27**
Text+Audio		75.28	**71.17**

표 1 KEMDy19 데이터셋을 사용한 감정인식 평가 결과

표 1은 각 모달 및 멀티모달의 CE, Mixup, CutMix, 그리고 제안하는 CutMix-SupCon 방법론의 KEMDy19 데이터셋 감정인식

실험 결과를 나타낸다. 실험 결과에 따르면, 멀티모달 관점에서 기존의 단순 결합 기반 CE 손실 함수를 사용한 방법은 69.08%의 F1-score를 얻었다. Mixup과 CutMix는 각각 68.94%, 70.77%의 성능을 얻었는데, 특히 Mixup은 기존 단순 결합 방법 대비 악화된 성능을 보이기도 하였다.

반면 제안하는 방법은 CE, Mixup, CutMix 대비 각각 멀티모달 관점에서 2.09%, 2.23%, 0.4%만큼의 F1-score가 개선됨을 보였다. 또한, 텍스트, 음성 모달을 각각 사용한 방법들에 대해서도 제안된 방법이 기존 방법들을 능가하는 것을 보였다. 결과적으로, 기존의 Mixup, CutMix 방법을 사용한 손실 함수가 단순 두 모달의 결합을 기반으로 CE 손실 함수를 사용하는 방법 대비 성능을 크게 개선하지 못했다는 점을 감안하면, 제안하는 CutMix-SupCon 방법으로부터 잠재 공간에서의 혼합 대조 학습이 매우 효과적이라는 것을 알 수 있다.

3.3 결과 분석

SupCon 방법은 배치 크기가 클수록 분류 성능에 더욱 효과적이지만, 본 연구에서는 음성 모달의 큰 GPU 메모리 요구량으로 인해 배치 크기를 4로 제한하여 실험하였다. 본 장에서는 CutMix-SupCon의 배치 크기별 성능을 확인하기 위해, 상대적으로 적은 GPU 메모리를 요구하는 텍스트 모달을 활용하여 성능 차이를 제공한다. 또한, CutMix-SupCon과 CE 간의 예측 확률 분포에 대한 분석 결과 제공을 통해 차이를 분석한다.

Batch Size	Best Hyperparams		Acc (%)	F1-score (%)
	τ	α		
4	0.2	0.25	72.49	69.72
8		0.25	71.86	68.97
16		0.5	73.28	**69.92**

표 2 CutMix-SupCon의 배치 크기별 텍스트 모달 기반 감정인식 성능

표2는 텍스트 기반 CutMix-SupCon 실험 결과를 나타내며, 배치 크기를 제외한 나머지 하이퍼파라미터 값들은 3.1 실험 세팅에서 언급한 내용과 같다. 동일한 학습률을 기준으로 배치 크기가 16일 때 가장 높은 성능을 달성하였는데, 4일 때보다 0.2%만큼 개선되었다. 하지만 배치 크기가 8일 때에는 4일 때보다 0.75%만큼 낮은 성능을 보였는데, 이는 추후 하이퍼파라미터 최적화 작업을 통해 개선될 것으로 기대된다.

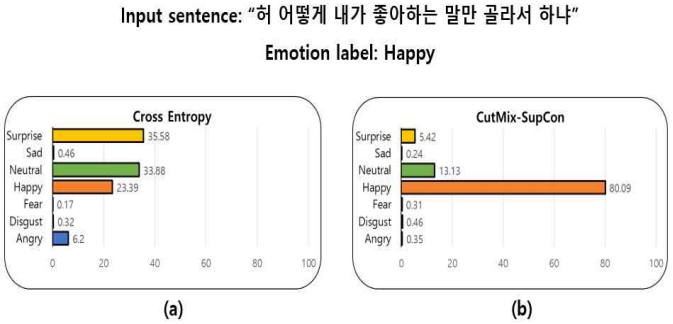

그림 2 KEMDy19 테스트 데이터 샘플에 대한 CE와 CutMix-SupCon의 예측 확률 분포 비교

그림 2는 손실 함수 CE와 CutMix-SupCon 방법을 사용했을 때 KEMDy19 테스트 데이터셋 샘플의 예측 확률 분포를 나타낸다. 분류 문제를 해결할 때 주로 사용되는 CE는 그림 2의 (a)에서 보이는 것처럼 "Surprise, Neutral, Happy" 클래스 예측 확률 분포가 유사하며, 이는 모델이 입력 문장에 대해 혼동되는 것으로 보인다. 대조적으로 그림 2의 (b)에서 볼 수 있듯이, 본 논문에서 제안한 CutMix-SupCon 방법론의 경우 "Happy" 클래스에 대해 높은 확률로 예측하는 것을 볼 수 있는데 이는 해당 방법론이 클래스 내의 분산을 줄임으로써 모델이 혼동하는 것을 방지할 수 있기 때문으로 보인다.

결과적으로, 제안하는 CutMix-SupCon 방법을 통해 정답 클래스 간 확률을 높이도록 범주형으로 학습하여 클래스 간의 관계를 학습하지 못하는 CE 손실 함수의 문제점을 잠재 공간 내에서 혼합된 정보를 원본 멀티모달 데이터 샘플과 얼마나 유사한지에 대한 효과적인 대조 학습을 통해 해결하는 것을 보였다.

4. 결 론

본 논문에서는 멀티모달 데이터셋의 불충분한 문제를 해결하기 위해 CutMix-SupCon 방법을 제안하였다. 제안된 CutMix-SupCon은 잠재 공간에서 추출된 음성-텍스트 모달 간의 결합된 특징표현으로부터 혼합된 특징표현이 생성되어 원본과 얼마나 유사한지 학습이 진행되는 방법론이다. 실제로 제안된 방법은 KEMDy19 데이터셋 평가에서 기존 방법대비 각 모달 및 멀티모달 관점에서 우수한 성능을 입증하였다. CutMix-SupCon 방법을 통해 감정인식 작업뿐만 아니라 멀티모달 기반의 다양한 작업에서 부족한 데이터 문제를 해결할 수 있을 것으로 기대한다.

참 고 문 헌

[1] Yoon, Seunghyun, et al. "Multimodal speech emotion recognition using audio and text." *2018 IEEE Spoken Language Technology Workshop (SLT)*. IEEE, 2018.

[2] Choi, Woo Yong, et al. "Convolutional attention networks for multimodal emotion recognition from speech and text data." *Proceedings of grand challenge and workshop on human multimodal language (Challenge-HML)*. 2018.

[3] Xu, Haiyang, et al. "Learning Alignment for Multimodal Emotion Recognition from Speech." *Proc. Interspeech 2019* (2019): 3569-3573.

[4] Majumder, Navonil, et al. "Multimodal sentiment analysis using hierarchical fusion with context modeling." *Knowledge-based systems* 161 (2018): 124-133.

[5] Zhang, Hongyi, et al. "mixup: Beyond empirical risk minimization." *arXiv preprint arXiv:1710.09412* (2017).

[6] Yun, Sangdoo, et al. "Cutmix: Regularization strategy to train strong classifiers with localizable features." *Proceedings of the IEEE/CVF international conference on computer vision*. 2019.

[7] Khosla, Prannay, et al. "Supervised contrastive learning." *Advances in neural information processing systems* 33 (2020): 18661-18673.

[8] Babu, Arun, et al. "XLS-R: Self-supervised cross-lingual speech representation learning at scale." *arXiv preprint arXiv:2111.09296* (2021).

[9] Baevski, Alexei, et al. "wav2vec 2.0: A framework for self-supervised learning of speech representations." *Advances in neural information processing systems* 33 (2020): 12449-12460.

[10] Park, Sungjoon, et al. "Klue: Korean language understanding evaluation." *arXiv preprint arXiv:2105.09680* (2021).

[11] Liu, Yinhan, et al. "Roberta: A robustly optimized bert pretraining approach." *arXiv preprint arXiv:1907.11692* (2019).

[12] Noh, Kyoung Ju, et al. "Multi-path and group-loss-based network for speech emotion recognition in multi-domain datasets." *Sensors* 21.5 (2021): 1579.